In [1]:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

import sklearn as sk
```

In [14]:

```
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score
from sklearn.neighbors import KNeighborsClassifier
from sklearn import svm


%matplotlib inline
```

Pratique avec le dataset Titanic

In [3]:

```
#charger les données
df=pd.read_csv('./titanic/train.csv')
```

In [5]:

```
#verifier que le chargement  est bon et voir à quoi ressemble le dataframe
df.head(5)
```

Out[5]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

In [6]:

```
# vérifer les dimensions
df.shape
```

Out[6]:

```
(891, 12)
```

In [7]:

```
df.describe()
```

Out[7]:

	PassengerId	Survived	Pclass	Age	SibSp	Parch	Fare
count	891.000000	891.000000	891.000000	714.000000	891.000000	891.000000	891.000000
mean	446.000000	0.383838	2.308642	29.699118	0.523008	0.381594	32.204208
std	257.353842	0.486592	0.836071	14.526497	1.102743	0.806057	49.693429
min	1.000000	0.000000	1.000000	0.420000	0.000000	0.000000	0.000000
25%	223.500000	0.000000	2.000000	20.125000	0.000000	0.000000	7.910400
50%	446.000000	0.000000	3.000000	28.000000	0.000000	0.000000	14.454200
75%	668.500000	1.000000	3.000000	38.000000	1.000000	0.000000	31.000000
max	891.000000	1.000000	3.000000	80.000000	8.000000	6.000000	512.329200

In [8]:

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
 #   Column       Non-Null Count  Dtype  
---  ------       --------------  -----  
 0   PassengerId  891 non-null    int64  
 1   Survived     891 non-null    int64  
 2   Pclass       891 non-null    int64  
 3   Name         891 non-null    object 
 4   Sex          891 non-null    object 
 5   Age          714 non-null    float64
 6   SibSp        891 non-null    int64  
 7   Parch        891 non-null    int64  
 8   Ticket       891 non-null    object 
 9   Fare         891 non-null    float64
 10  Cabin        204 non-null    object 
 11  Embarked     889 non-null    object 
dtypes: float64(2), int64(5), object(5)
memory usage: 83.7+ KB
```

La signification des colonnes :

PassengerID : identifiant

Survived : 0 si ce passager n'a pas survécu, 1 sinon

Pclass : la classe (1, 2 ou 3)

Name : le nom du passager

Sex : femme ou homme (sexe)

Age : l'âge (en années)

SibSp : le nombre de frère, soeur et/ou épouse à bord

Parch : le nombre de parent et/ou d'enfant à bord

Ticket : numéro du ticket

Fare : prix du billet

Cabin : numéro de cabine

Embarked : port d'embarquement(C = Cherbourg, Q = Queenstown, S = Southampton)

Dans un premier temps on va essayer de comprendre les données

- Lire et explorer le dataset à partir des fichiers csv.

In [8]:

```
df = pd.read_csv('./titanic/train.csv')
df.head()
```

Out[8]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

- Vérifier si le dataset contient des valeurs manquantes ?

In [9]:

```
df.isna().sum()
```

Out[9]:

```
PassengerId      0
Survived         0
Pclass           0
Name             0
Sex              0
Age            177
SibSp            0
Parch            0
Ticket           0
Fare             0
Cabin          687
Embarked         2
dtype: int64
```

- Proposer une solution pour remplacer les valeurs manquantes.

Pour la cabine on peut estimer que le numero n'est pas interessant pour predire la survie. On peut retirer cette colonne ou bien remplacer les valeurs maquantes par une valeur "dummy" c'est a dire qui ne porte pas d'information. Par exemple "inconnu". Pour l'age il y a beaucoup de possibilites, on peut essayer de le predire à partir des autres informations, par exemple en fonction du prix du billet. On peut aussi prendre l'âge moyen, la moyenne des ages des N personnes ayant payé le prix du billet le plus proche etc.

- Est il possible de visualiser les données ?

Il y a de nombreuses facon, en voici quelques exemples :

In [10]:

```
temp = df.dropna() # on retire les nan pour eviter les erreurs d'affichage
```

In [15]:

```
def get_survived_color(survived):
    return "green" if survived else "red"

for row in temp.itertuples():
    plt.scatter(row.Age, row.Fare, color=get_survived_color(row.Survived))

plt.title("Prix en fonction de l'âge (vert pour survecu, rouge sinon)");
```

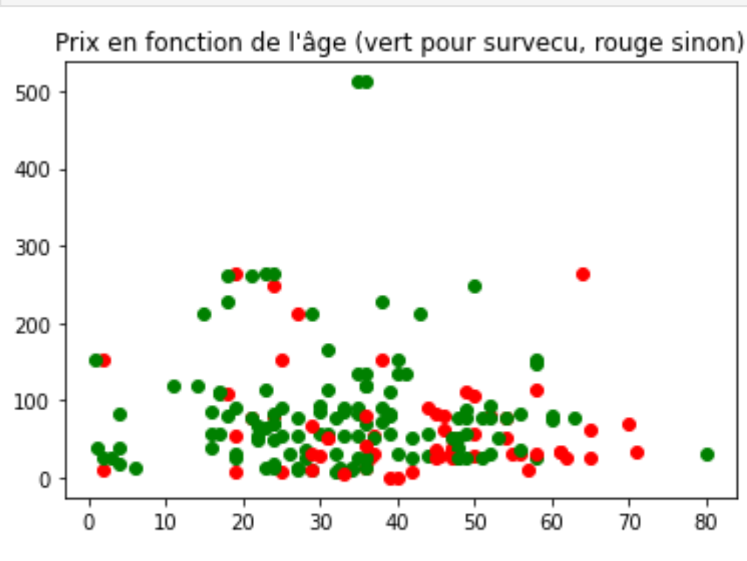

In [16]:

```
def get_sex_color(sex):
    return "yellow" if sex=="male" else "blue"

for row in temp.itertuples():
    plt.scatter(row.Age, row.Fare, color=get_sex_color(row.Sex))

plt.title("Prix en fonction de l'âge (bleu pour les femmes, jaune pour les hommes)");
```

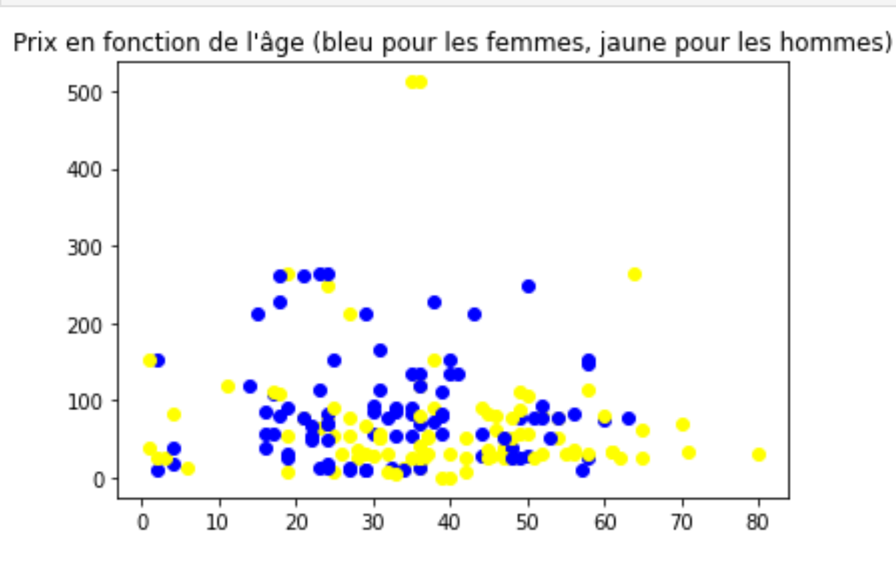

In [18]:

```
N = 3 # 3 classes
width = 0.35       # la largeur des barres

survived_per_class = [ temp[temp.Pclass == x].Survived.sum() for x in [1, 2, 3] ]
not_survived_per_class = [ np.abs(temp[temp.Pclass == x].Survived - 1).sum() for x in [1, 2, 3] ]
ind = np.arange(N)

p1 = plt.bar(ind, survived_per_class, width)
p2 = plt.bar(ind, not_survived_per_class, width,
             bottom=survived_per_class)

plt.ylabel('Nombre de personnes')
plt.title('Survie par classe')
plt.xticks(ind, ('1', '2', '3'))
plt.legend((p1[0], p2[0]), ('Survecu', 'Pas survecu'))
```

Out[18]:

```
<matplotlib.legend.Legend at 0x132535610>
```

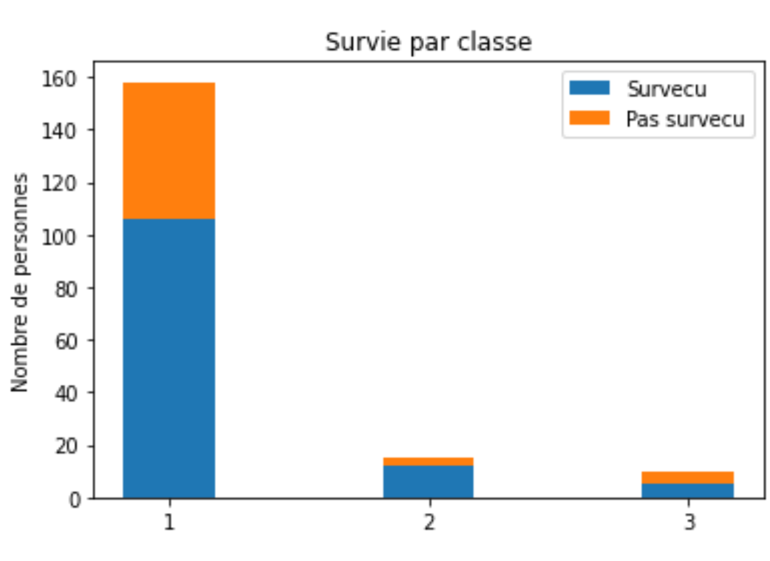

- Créer une nouvelle colonne qui mentionne le sexe du passager.

In [19]:

```
df["sex_as_int"] = (df['Sex'] == 'male').astype(int)
df.head()
```

Out[19]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	sex_as_int
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S	1
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C	0
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S	0
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S	0
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S	1

- Combien de personnes ont survécu ?

In [20]:

```
df.Survived.sum()
```

Out[20]:

```
342
```

- Est ce que la Pclass a plus d'importance que l'âge pour la survie ?

Pour répondre à cette question, nous allons tester la classification : survived en fontion de l'âge (repectivement Pclass). On peut tirer une conclusion à partir de la performance mais relativement au modèle utilisé.

In [21]:

```
y = temp.pop("Survived")
```

In [22]:

```
Xtrain, Xtest, ytrain, ytest = train_test_split(temp, y,test_size=0.25, random_state=0)
```

In [23]:

```
def get_classification_score(dataset, list_of_features, label, model=svm.SVC(gamma=0.001), dropna=True):
    temp = dataset.copy()
    if dropna:
        temp = temp.dropna()

    y = temp.pop(label)

    Xtrain, Xtest, ytrain, ytest = train_test_split(temp, y,test_size=0.25, random_state=0)

    Xtrain = Xtrain[list_of_features].values
    Xtest = Xtest[list_of_features].values

    if len(Xtrain.shape) < 2:
        Xtrain = Xtrain.reshape(-1, 1)

    if len(Xtest.shape) < 2:
        Xtest = Xtest.reshape(-1, 1)

    model.fit(Xtrain,ytrain)

    ypredit = model.predict(Xtest)
    return accuracy_score(ytest, ypredit)


def compare_features(
    dataset,
    list_of_features_1,
    list_of_features_2,
    label,
    dropna = True
    ):

    score_1 = get_classification_score(dataset, list_of_features_1, label)
    score_2 = get_classification_score(dataset, list_of_features_2, label)

    print(f"Avec les colonnes {list_of_features_1}, le score est de {score_1}.")
    print(f"Avec les colonnes {list_of_features_2}, le score est de {score_2}.")
```

In [24]:

```
compare_features(df, ["Pclass"], ["Age"], "Survived")
```

```
Avec les colonnes ['Pclass'], le score est de 0.8043478260869565.
Avec les colonnes ['Age'], le score est de 0.7391304347826086.
```

Dans un deuxième temps on va transformer quelques colonnes

- Transformer le sexe en nombre

In [25]:

```
df["Sex"] = (df['Sex'] == 'male').astype(int)
df.head()
```

Out[25]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	sex_as_int
0	1	0	3	Braund, Mr. Owen Harris	1	22.0	1	0	A/5 21171	7.2500	NaN	S	1
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	0	38.0	1	0	PC 17599	71.2833	C85	C	0
2	3	1	3	Heikkinen, Miss. Laina	0	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S	0
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	0	35.0	1	0	113803	53.1000	C123	S	0
4	5	0	3	Allen, Mr. William Henry	1	35.0	0	0	373450	8.0500	NaN	S	1

- On teste si (âge et sexe) est mieux que (classe, sexe)

In [31]:

```
df = pd.read_csv('./titanic/train.csv')
df = df.dropna()

df["Sex"] = (df['Sex'] == 'male').astype(int)

compare_features(df, ["Age", "Sex"], ["Pclass", "Sex"], "Survived")
```

```
Avec les colonnes ['Age', 'Sex'], le score est de 0.7391304347826086.
Avec les colonnes ['Pclass', 'Sex'], le score est de 0.8043478260869565.
```

- On teste la performance des trois

In [32]:

```
df = pd.read_csv('./titanic/train.csv')
df = df.dropna()

df["Sex"] = (df['Sex'] == 'male').astype(int)

get_classification_score(df, ["Age", "Sex", "Pclass"], "Survived")
```

Out[32]:

```
0.7391304347826086
```

- Proposer comment transformer d'autres colonnes

La colonne Embarked peut être transformée en int

In [29]:

```
def encode_embarked(code):
    if code == "Q":
        return 0
    if code == "S":
        return 1
    if code == "C":
        return 2

    raise Exception(f"Unknown code: {code}")
```

- Tester l'importance de chaque colonne à part, des combinaisons, etc.

- Conclure après plusieurs tests : modèles + features

In [30]:

```
def generate_random_features_list(all_features, max_features=-1):
    if max_features == -1:
        return all_features
    n_features = np.random.randint(1, max_features+1)
    return np.random.choice(all_features, size=n_features, replace=False)

def get_random_model():
    Arbre_decision = DecisionTreeClassifier(random_state=0, max_depth=20)
    KNN = KNeighborsClassifier()
    svc = svm.SVC(gamma=0.001)

    return np.random.choice([Arbre_decision, KNN, svc], size=1)[0]
```

In [33]:

```
df = pd.read_csv('./titanic/train.csv')
df = df.dropna()

df["Sex"] = (df['Sex'] == 'male').astype(int)
df["Embarked"] = df["Embarked"].apply(encode_embarked)

all_features = ['Pclass', 'Sex', 'Age', 'SibSp',
        'Parch', 'Fare', 'Embarked']
```

In [34]:

```
for i in range(30):
    features = generate_random_features_list(all_features, len(all_features))
    score = get_classification_score(df, features, "Survived")
    model = get_random_model()
    print(f"{model} + {features} : {score}")
```

```
KNeighborsClassifier() + ['Fare' 'Parch' 'Age' 'Sex'] : 0.8043478260869565
SVC(gamma=0.001) + ['Fare'] : 0.8260869565217391
KNeighborsClassifier() + ['Sex' 'Embarked' 'Pclass' 'Age' 'SibSp' 'Parch'] : 0.7391304347826086
SVC(gamma=0.001) + ['Fare'] : 0.8260869565217391
SVC(gamma=0.001) + ['Embarked' 'Sex' 'SibSp' 'Age'] : 0.7391304347826086
KNeighborsClassifier() + ['Embarked'] : 0.8043478260869565
SVC(gamma=0.001) + ['Parch' 'Pclass'] : 0.8043478260869565
SVC(gamma=0.001) + ['Age' 'SibSp' 'Embarked'] : 0.7391304347826086
KNeighborsClassifier() + ['Pclass' 'Age' 'Sex'] : 0.7391304347826086
SVC(gamma=0.001) + ['Pclass' 'Age' 'SibSp' 'Sex' 'Parch'] : 0.7391304347826086
SVC(gamma=0.001) + ['Age'] : 0.7391304347826086
KNeighborsClassifier() + ['Age' 'Embarked' 'SibSp' 'Fare'] : 0.8043478260869565
DecisionTreeClassifier(max_depth=20, random_state=0) + ['Fare' 'Age' 'Parch' 'SibSp'] : 0.8043478260869565
DecisionTreeClassifier(max_depth=20, random_state=0) + ['Fare' 'Age' 'SibSp' 'Embarked'] : 0.804347826086956
5
KNeighborsClassifier() + ['Parch' 'Sex'] : 0.8043478260869565
SVC(gamma=0.001) + ['Age' 'Sex' 'Fare' 'Embarked'] : 0.8043478260869565
KNeighborsClassifier() + ['Fare' 'Embarked'] : 0.8260869565217391
SVC(gamma=0.001) + ['SibSp' 'Sex'] : 0.8043478260869565
SVC(gamma=0.001) + ['Age' 'SibSp' 'Embarked'] : 0.7391304347826086
SVC(gamma=0.001) + ['Fare' 'Age' 'Parch' 'Sex' 'Pclass'] : 0.8043478260869565
SVC(gamma=0.001) + ['Fare' 'SibSp' 'Embarked' 'Pclass' 'Parch' 'Sex' 'Age'] : 0.8043478260869565
KNeighborsClassifier() + ['Fare' 'SibSp' 'Pclass' 'Age' 'Sex' 'Parch' 'Embarked'] : 0.8043478260869565
SVC(gamma=0.001) + ['Sex'] : 0.8043478260869565
DecisionTreeClassifier(max_depth=20, random_state=0) + ['Fare' 'Embarked' 'Pclass' 'Parch'] : 0.826086956521
7391
SVC(gamma=0.001) + ['SibSp' 'Fare' 'Sex' 'Embarked' 'Pclass' 'Parch'] : 0.8260869565217391
SVC(gamma=0.001) + ['Sex' 'Age' 'Embarked' 'Fare' 'Parch' 'Pclass' 'SibSp'] : 0.8043478260869565
barked' 'Sex' 'Age' 'Parch'] : 0.7391304347826086
```